

ColdX × DeepSeek V4.1

研究与真实评测

由 ChatGPT 自动化执行并整理。受用户委托提供给老师审阅。

本次把原生 ColdX 放进官方 DeepSWE v1.1 任务容器，使用 DeepSeek 官方 API 和独立验证器。先完成三道预先固定的 Go、Python、TypeScript 题目，检查生成质量、执行可靠性与费用。

本轮实测

任务	官方验证	总耗时
Go：模块缓存与路径	通过	11 分 42 秒
Python：字段命名与别名	通过	16 分 22 秒
TypeScript：JSON Schema 引用	未通过	29 分 37 秒

本轮固定三题中，2 题通过官方验证。结果只描述这三次运行，不是全量 benchmark 成绩。

这是三题、每题一次的流程试跑。它不能代表 113 题 × 8 次的 DeepSWE 全量成绩，也不能证明 ColdX 已经超过 Codex 或其他 agent。未完成、基础设施错误和用户中断不会填成 0 分。

可以据此做出的判断

TypeScript 题原回归 1679/1679、新增验收 23/25 通过，但递归引用与 anyOf 联合分支的组合缺陷导致任务失败。模型做了真实自测，却遗漏了需求明确提醒的边界；应优先加强组合验收与完成声明的证据。

此前的生成质量与成本研究已整理为完整文档。提示词、工具选择、记忆和上下文压缩的候选改进仍需受控 A/B 测试；当前没有将候选优化收益写成已证实结论。

完整报告、脚本与图表：[GitHub 研究索引](#)

怎样让模型更自主、更务实

质量优先意味着先检查交付和证据，再比较费用。现有资料更支持改进执行环境与反馈，而不是不断追加长系统提示。下面是下一轮实验的工程方向，不是本轮已经测出的提升幅度。

方向	具体做法与验收
协议与完成语义	核验实际模型路由、reasoning 回放、工具调用和 usage；无正文、截断或工具失败不能直接标成完成。
页面生成闭环	明确交付与交互要求，实际运行页面，检查 DOM、截图、控制台与真实操作；依据具体失败修复后复验。
工具与子智能体	保持根工具职责清楚、顺序稳定；把独立任务交给子智能体，保留负责范围、结果、失败和汇总证据。
上下文治理	工具结果首次进入上下文时提取有效信息，完整日志留在可恢复文件中；保留约束、决定、证据和未完成事项。
长期记忆	从有来源、时间和适用范围的任务记录起步；先验证检索收益，再决定是否增加向量或图数据库。
推理档位与恢复	以可执行失败触发有界恢复；比较 high/max 的质量与总费用，避免无限反思或只挑成功重跑。

怎样对待“民间偏方”

短思维草稿、重复提示、语言切换或措辞模板可以作为实验候选，但其他模型的论文、少量成功案例和社区经验不能直接证明 V4.1 的提升。必须固定任务、环境和评分，保留失败与额外费用。

详细论证与来源：V4.1 性能与 token 效率研究；生成质量底层研究

费用、token 与缓存

费用从最外层模型转发记录核算，包含主任务、辅助调用和原生重试。两层代理只计一次；reasoning 已包含在输出 token 中，不再重复收费。缓存命中率高也不等于任务质量高。

任务	累计输入	缓存占比	输出	观测费用
Go	18.78 M	99.44%	81.9 K	约 ¥0.807
Python	27.03 M	99.53%	131.5 K	约 ¥1.192
TypeScript	31.32 M	99.56%	148.6 K	约 ¥1.354

本轮三题已报告用量的价目估算合计约 ¥3.353。HTTP 收尾与 usage 覆盖分别记录；部分连接被客户端取消，计量完整性仍保持保守标记。它不是供应商最终账单。

价格口径

按本轮北京时间周日的官方谷时价格估算，每百万 token：缓存输入 ¥0.02、未缓存输入 ¥1、输出 ¥4。价格与时段会变化；模型用量估计和供应商结算账单分开。[1]

费用 = (缓存输入 token × 命中价 + 未缓存输入 token × 未命中价 + 输出 token × 输出价) ÷ 1,000,000。
单价单位为元/百万 token。表中的 token 都是累计调用用量，不是同时占用的上下文大小。

为什么不只追求更少输入

在这份价格快照中，一个输出 token 的标价相当于 200 个缓存输入 token。反复返工和无效生成可能比保留稳定缓存更贵；随意重写历史又可能破坏已有缓存。先减少无关工具输出与错误行动，再用真实质量和账单比较压缩方案。

全量测试的资源预估

若 904 次都重复本轮三题的已报告平均用量，DeepSWE 谷时情景约 ¥1,010，按代理平均生命周期串行约 290 小时。这是条件算术，不是可靠预算预测。本轮未启动这笔全量作业；Terminal-Bench 尚无实测成本。

DeepSWE 完整协议为 904 次，Terminal-Bench 为 267 次。两套任务耗时和费用分布不同；三道 DeepSWE 题不能提供 Terminal-Bench 的实测预算。

[1] DeepSeek 官方定价

可比较的部分与复现边界

项目	本次记录
被测对象	ColdX 0.1.2 / 原生 DSH 0.1.1-rc.2；保留产品工具与任务循环。
模型参数	官方 deepseek-flash；max effort；请求 temperature=1、top_p=0.95；1M context。thinking 下温度是否生效遵循供应商协议。
环境	原始固定 Docker 镜像；每题 2 CPU、8 GiB 内存；任务终端离线，推理仅经受限代理。
预算与评分	每 agent 500 步；每题额外 5000 请求试跑上限；独立原始 verifier，所有有效 0/1 奖励均保留。
已公开输入	固定源码提交、policy 评测快照、源码清单、runtime digest、工具脚本、任务与 Pier 提交及环境补丁来源。
已知差异	官方未完整公开定制 harness、TB 版本与离线准备；原 Pier 的磁盘配额仅声明未硬性实施。本次不能宣称精确复现官方全部环境。

官方其他 agent 的分数如何使用

附件中的八框架对照图重绘自 DeepSeek 官方报告，使用同一模型，但不是本机重跑结果。ColdX 三题图单独展示。只有完成匹配的完整任务集和次数后，才有资格讨论可比较的全量分数。

官方参考表：[固定版本模型卡](#)

完整执行条件：[本次公开协议与限制](#)

完整材料与下一步

附件资料包按以下顺序阅读。GitHub 中保留可点击来源、实验矩阵和脚本；PDF 作为摘要，完整 Markdown 文档作为技术附件。

材料	包含什么
研究索引与本轮结果	真实奖励、耗时、观测用量、费用口径、版本与复现差异。
V4.1 性能 / token 效率	官方参数语义、缓存成本、上下文压缩、推理档位、民间方法证据分级与实验矩阵。
生成质量底层研究	工具设计、原生 harness、环境反馈、长期记忆、页面自主生成的验证闭环。
Agent harness 研究	DeepSeek 原生适配、工具与 thinking 回放、集成风险与改进路径。
评测代码与协议	ColdX 原生入口、隔离转发、Pier 适配、聚合与绘图、固定版本和测试说明。
图表与结构化结果	官方参考图与独立 ColdX 试跑图；不混合样本范围，不把缺失结果补零。

后续实验应先冻结再执行

用本轮基线建立回归集，按“协议/完成语义 → 工具输出控制 → reasoning 档位 → 子智能体 → 记忆检索”逐项消融。每次只改变一个主要因素，保留全部尝试，比较正确性、总费用和完成时间；有稳定收益后再改默认配置。

账户密钥、私有聊天和机器上的私人文件不在公开材料中。原始运行记录在本地保留，公开版只提供经检查的结构化结果、哈希与复现输入。

我是 ChatGPT。这份材料是受用户委托、通过自动化执行与资料核查整理的结果。

[打开完整研究索引](#)